

INFORME TÉCNICO: ANÁLISIS EXPLORATORIO DE DATOS (EDA) – DATASET COVID-19

Origen de los datos: national-history.csv

Área de estudio: Ciencia de Datos / Epidemiología

Participantes: Ana Paula Montiel, Noelia Sánchez y Romina Navea

1. INTRODUCCIÓN Y OBJETIVOS

Este informe resume el procedimiento y las conclusiones obtenidas a partir del Análisis Exploratorio de Datos (EDA) aplicado al historial nacional de registros de la pandemia de COVID-19. El propósito principal de este estudio consistió en diagnosticar la calidad de la información, aplicar técnicas rigurosas de saneamiento y normalización de datos, evaluar el comportamiento de las métricas sanitarias mediante estadística descriptiva y validar hipótesis epidemiológicas mediante inferencia estadística.

Indicadores Clave Finales del Período

28.756.489	515.151	1,79%	98,21%
Casos positivos acumulados	Fallecimientos acumulados	Tasa de letalidad	Tasa de supervivencia

Objetivos principales del proyecto:

- Consumo, gestión y normalización de archivos en formato .csv.
- Auditoría de calidad, limpieza profunda y preprocesamiento de datos.
- Análisis visual interactivo y estadístico mediante librerías especializadas (matplotlib, seaborn y bokeh).
- Detección de anomalías/valores atípicos e implementación de pruebas de hipótesis estadísticas.

2. DATOS Y METODOLOGÍA

Auditoría de calidad y estructura original

El dataset cuenta con un total de **420 registros** (filas) y **17 columnas** (variables). Al realizar la carga inicial del marco de datos (DataFrame), se identificaron las siguientes inconsistencias estructurales:

Variable	Tipo	Descripción
date	Datetime	Fecha del registro diario
positiveIncrease	Int64	Nuevos casos positivos en el día
deathIncrease	Int64	Nuevos fallecimientos en el día
hospitalizedCurrently	Int64	Pacientes hospitalizados activos
inIcuCurrently	Int64	Pacientes en UCI activos
positive	Int64	Total acumulado de casos positivos
death	Int64	Total acumulado de fallecimientos

1. **Tipos de datos erróneos:** La variable temporal date se identificó originalmente como tipo texto (object). Adicionalmente, múltiples métricas estrictamente discretas (conteos de personas) como death, inIcuCumulative, inIcuCurrently, hospitalizedCurrently, hospitalizedCumulative, negative, onVentilatorCumulative, onVentilatorCurrently y positive se importaron como formato de punto flotante (float64) debido a la presencia de registros vacíos.
2. **Presencia de valores nulos (NaN):** El inventario de ausencias reveló vacíos considerables en columnas críticas de ocupación hospitalaria:
 - onVentilatorCumulative: 79 nulos.
 - inIcuCurrently: 73 nulos.
 - inIcuCumulative y onVentilatorCurrently: 72 nulos cada uno.
 - hospitalizedCurrently: 64 nulos.

- hospitalizedCumulative: 51 nulos.
- negative: 48 nulos.
- death: 28 nulos.
- positive: 1 nulo.

3. LIMPIEZA, SANEAMIENTO Y NORMALIZACIÓN DE DATOS

- Conversión de la columna date a formato datetime64 para correcta ordenación temporal.
- Normalización de 11 columnas numéricas de float64 a Int64 mediante pd.to_numeric con errors='coerce'.
- Imputación de valores nulos con fillna(0): ausencia de dato equivale a cero casos reportados.
- Verificación de duplicados: 0 filas duplicadas, 0 fechas repetidas.
- Dataset final: 420 registros completos, 0 valores nulos.

Para asegurar la confiabilidad matemática y analítica del modelo, se ejecutó un flujo secuencial de preprocesamiento:

1. **Cast Temporal:** Se transformó la columna date al tipo de dato nativo datetime64[ns], habilitando el ordenamiento cronológico y la segmentación por periodos mensuales.
2. **Conversión Forzada a Enteros:** Se implementó un bucle dinámico que utilizó pd.to_numeric(..., errors='coerce') sobre las 11 variables clave de conteo para asegurar su conversión al tipo Int64 de Pandas. Este formato nativo es indispensable ya que permite trabajar formalmente con números enteros sin perder la compatibilidad con valores faltantes (NaN).
3. **Imputación de Valores Faltantes:** Se determinó metodológicamente que las ausencias de reportes diarios en métricas de impacto hospitalario equivalen estadísticamente a un conteo de cero casos en dicho día específico. Se aplicó la función df.fillna(0) para neutralizar los vacíos sin sesgar los acumulados.
4. **Verificación de Integridad Cronológica:** Se evaluaron duplicaciones en el dataset mediante df.duplicated().sum() obteniendo **0 filas idénticas y 0 fechas repetidas**, lo que garantiza que la serie de tiempo es limpia, continua y consistente.

4. ESTADÍSTICA DESCRIPTIVA GENERAL

Una vez saneado el dataset (420 registros completos sin nulos), el análisis estadístico descriptivo (`df.describe()`) proporcionó las siguientes métricas de comportamiento general sobre el impacto acumulado y diario de la pandemia:

- **Fallecimientos Diarios** (`deathIncrease`): El promedio diario de muertes registradas fue de **1.226,55 personas**, registrando un pico máximo histórico de **5.427 muertes** reportadas en un solo día.
- **Fallecimientos Acumulados** (`death`): El total acumulado al cierre del registro llegó a las **515.151 muertes**.
- **Nuevos Casos Diarios** (`positiveIncrease`): La media de contagios diarios se situó en **68.467,83 casos**, alcanzando un alarmante pico máximo histórico de **295.121 contagios** en una sola jornada.
- **Casos Positivos Acumulados** (`positive`): El total de personas contagiadas desde el inicio del registro histórico alcanzó los **28.756.489 casos**.
- **Presión Hospitalaria Máxima**: En los momentos de mayor saturación, se registraron hasta **132.474 pacientes hospitalizados simultáneamente**, con un pico de **23.912 pacientes en Unidades de Cuidados Intensivos (UCI)** y **8.004 personas bajo ventilación mecánica** en un mismo día.

5. DETECCIÓN Y ANÁLISIS MATEMÁTICO DE OUTLIERS

Para evaluar si los incrementos diarios correspondían a fluctuaciones típicas o a eventos extraordinarios (olas de contagio o retrasos de reporte), se analizó la variable `positiveIncrease` (Nuevos Casos Diarios) empleando el método del **Rango Intercuartílico (IQR)**:

- **Cálculo de Límites Estadísticos**: Con un Tercer Cuartil del 75% ubicado en 89.684,25 casos y un Primer Cuartil del 25% en 22.462,50 casos, el Rango Intercuartílico resultante fue de $IQR = 67.221,75\$$.
- Estableciendo el umbral de normalidad superior a través de la fórmula matemática $Q3 + 1.5 \times IQR$, se fijó el límite superior en **190.516,88 casos diarios**. Cualquier registro por encima de este valor se considera un *outlier* estadístico o anomalía.
- **Resultados del Filtrado**: Se detectaron **40 días atípicos** en el dataset que rompieron este límite superior.
- **Cronología de los Picos Críticos**: Al extraer y ordenar de forma descendente las jornadas más extremas, se identificó un patrón de concentración epidemiológica crítica a principios de enero de 2021:

1. **08-01-2021:** 295.121 casos positivos (Máximo pico absoluto).
2. **02-01-2021:** 280.318 casos positivos.
3. **07-01-2021:** 272.043 casos positivos.
4. **09-01-2021:** 269.368 casos positivos.
5. **06-01-2021:** 250.184 casos positivos.

Este comportamiento revela inequívocamente que la primera semana de enero de 2021 representó el periodo de mayor descontrol en la tasa de contagios de toda la serie histórica.

6. INFERENCIA ESTADÍSTICA: PRUEBA DE HIPÓTESIS (T-TEST)

A fin de determinar si el impacto de la pandemia sufrió alteraciones reales y estadísticamente significativas entre los años de registro, se planteó un análisis comparativo formal de las medias de mortalidad diaria (deathIncrease) entre los periodos anuales de 2020 y 2021.

Formulación Estadística:

- **Hipótesis Nula:** La media de muertes diarias en el año 2020 es estadísticamente idéntica a la del año 2021.
- **Hipótesis Alternativa:** Existe una diferencia significativa entre las medias de muertes diarias de ambos años.

Datos Muestrales Calculados:

- **Media de muertes diarias en 2020:** 951,42 (sobre un total de 354 días registrados).
- **Media de muertes diarias en 2021:** 2.702,26 (sobre un total de 66 días registrados).

Resultados del T-Test de Student:

- **Estadístico T calculado:** -12,1405.
- **p-valor obtenido:** $1,186414 \times 10^{-19}$ (un valor infinitamente menor al nivel de significancia estándar $\alpha = 0,05$).

Conclusión:

Debido a que el p-valor tiende prácticamente a cero, **se RECHAZA categóricamente la Hipótesis Nula H_0** . El cambio en la velocidad y el volumen de decesos es estadísticamente **altamente significativo**.

La media de muertes diarias casi se triplicó a principios de 2021 en comparación con el año anterior (pasando de 951 a 2.702 fallecimientos al día). Esto demuestra formalmente que la dinámica de la pandemia mutó de forma agresiva y real entre ambos periodos, atribuible a factores biológicos y ambientales como la aparición de variantes de mayor transmisibilidad, la saturación acumulada del sistema clínico o el comportamiento social tras las festividades de fin de año.